MARCH, 2026

# KAZAKH MISSING WORD

by Push & Pray

# TABLE OF CONTENT

1. TASK DESCRIPTION
2. MODEL ARCHITECTURE
3. HOW WE IMPROVED
4. RESULTS
5. IDEAS FOR IMPROVEMENT
6. TECHNICAL UNDERSTANDING

# 1. TASK DESCRIPTION

## GOAL

Predict the indexed position of a missing word in a Kazakh sentence.

No marker shows where the word is missing — the model must infer from context.

## DATASET

Train set: 554k full sentences

Labeled set: 99k (text + position label)

Test set: 15,000 sentences with one word removed

```
text,label
мәжіліс депутаттары осы туралы келісімді ратификациялау жобасын мақұлдады,0
өте ыңғайлы ризамыз,3
атап айтқанда философ еркіндіктегі себептілік идеясы арқылы жаңа заман ойшылдарының біразына айтты,11
ол құйтырқы әрекетін выгодный займ ұйымының басшысы жанболат есіркеповке сілтеп жуып шаймақ,1
қазақтар қырғыздар өзбектердің сыртқы жауға қарсы күресте өзара одақтасуы туралы құнды мәліметтер сақталған,2
тағы да рақымғали төлеубеков тәжірибесіне тоқталсам рақаң совхоздағы он басшы маманның жартысына жуығына жастарды тағайындайты
жігіт үйге кіре кетпес пе деп дәметеді,5
дереу үлкен ит әкелді,0
осы ерік күшіміздің арқасында бір жылдар бойғы арманымымызға қол жеткізу үшін бір сәттік пен рахаттан бас тарта аламыз,13
есімі тұрсын мұхаммед сұлтан,0
бүгінде вирус алпыстан астам елде оны жұқтырғандардың саны тоқсан мыңнан асты,5
мен ұнатамын келіншек деген сөзді ақын көремін сені түсімде орының әсте бөлек қой,0
өзім көтеріп алмайтын компьютерге сенбеймін,2
жарлы зарлы демейді кеңінен ашып көмейді түйесін жұтам десе қай сорлы қалтқы болып бөгейді,6
басында тігінші боп жай ғана практикант болып,3
бүгін шынар емтихан тапсырып келсе түнделетіп жолға шығып,1
содан түн ортасында ақ келеді,3
```

# MODEL ARCHITECTURE

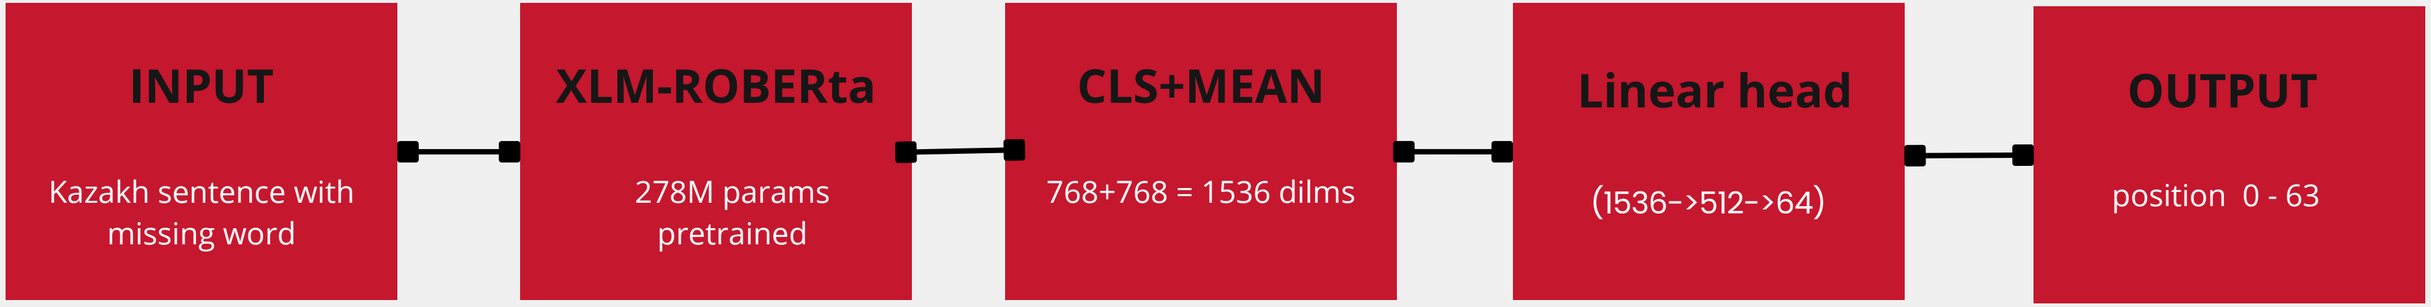


## Token Alignment

words: [бүгін] [депутаттары] [мақұлдады]

tokens: [бүг][ін] [депу][тат][тары] [мақұл][дады]

1st token: pos* = 0 pos = 2 pos = 5 → model knows word boundaries

*позиция первого токена слова

# HOW WE IMPROVED

1. **Text cleaning**
- removed extra places and duplicates  from training data
2. **CLS + Mean Pooling**
- Combined CLS (768) + mean pooling (768) = 1536 dimensional representation
3. **Label Smoothing**
- CrossEntropyLoss(label_smoothing=0.1) prevents overconfidence
4. **More Data**
- Used up to 250k labeled samples instead of 100k — biggest single improvement

# RESULT

**0.307 → 0.5348**

**72% improvement**

# IDEAS FOR IMPROVEMENT

Training on more data

Kazakh specific model

better morphology understanding

Larger XLM-ROBERTa

more parameters

# TECHNICAL UNDERSTANDING

## Training process

- **AdamW optimizer**
(lr=2e-5, weight_decay=0.01)
- **Linear warmup scheduler**
(10% of total steps)
- **Gradient clipping**
(max_norm=1.0)
- **Label smoothing = 0.1**
- **90/10 train/val split**
- **Best model saved by val_acc**

## Validation and inference

- **OVERFITTING CHECK:**
TRAIN_ACC ≈ VAL_ACC → NO OVERFITTING

- **INFERENCE:**
LOAD BEST_MODEL.PT → PREDICT 15K TEST SAMPLES → SORT BY ID → SAVE SUBMISSION.CSV

- **REPRODUCIBILITY:**
RANDOM_STATE=42 EVERYWHERE → SAME RESULTS EVERY RUN. RUNS IN < 2 HOURS WITH BATCH_SIZE=64

# THANK YOU